Bitirme Projesi · Vize Sunumu

Veri Yapıları ve Algoritmalar için Domain Corpus ve Instruction Dataset

Proje: Ders Müfredatına Özel Fine-Tune Edilmiş SLM ve RAG Tabanlı Adaptif Sınav Hazırlama ve Öğrenme Asistanı

Sedef Gizem Orulluoğlu

2211012047 · Bilgisayar Mühendisliği

Danışman: Asım Sinan Yüksel

Süleyman Demirel Üniversitesi

Mühendislik ve Doğa Bilimleri Fakültesi

Alan ve amaç

Hedef: DSA dersini alan öğrencinin sorularını Türkçe ve kaynağa dayanarak cevaplayan küçük bir dil modeli

Vizede teslim

Domain Corpus v1.0

Modele alanı öğretir. Final döneminde **CPT**'de kullanılacak.

Vizede teslim

Instruction Dataset v1.0

Modele görev yapmayı öğretir. Final döneminde **SFT**'de kullanılacak.

Final dönemi

Değerlendirme

Modelin ne kadar başarılı olduğunu ölçer. Vizede zorunlu değil.

Vize kapsamı: model eğitimi yok. İki veri seti, iki dataset card ve her şeyi baştan üreten pipeline (13 script).

Veri ihtiyacı

Lisans düzeyindeki giriş dersinin konuları, açık lisanslı kaynaklardan

Kapsam içi

Diziler ve bağlı listeler, yığıt ve kuyruk, hash tabloları, ağaçlar (BST, AVL, kırmızı-siyah, heap, trie), graflar, sıralama ve arama, karmaşıklık analizi, özyineleme ve dinamik programlama, algoritma paradigmaları

Kapsam dışı

İşletim sistemleri, veritabanı iç yapısı, bilgisayar ağları, kriptografi, NP-tamlık ispatları gibi ileri teori, sayısal lineer cebir

Açık lisanslı, ders düzeyinde **Türkçe** DSA kaynağı bulamadım. Alan bilgisi ağırlıkla İngilizce kaynaklardan geliyor; Türkçe cevap vermeyi Instruction Dataset öğretiyor.

Veri kaynakları

6 açık lisanslı kaynak, 609 ham doküman

Kaynak	Tür / dil	Ham	Final	Lisans
İngilizce Vikipedi (elle seçilmiş maddeler)	HTML · en	405	397	CC BY-SA 4.0
TheAlgorithms/Python	Kod · Python	100	100	MIT
Türkçe Vikipedi (elle seçilmiş maddeler)	HTML · tr	69	54	CC BY-SA 4.0
Open Data Structures (Pat Morin)	PDF · en	14	14	CC BY 2.5 CA
Open Guide to DSA (PALNI)	HTML · en	11	11	CC BY 4.0
Algorithms (Jeff Erickson)	PDF · en	10	10	CC BY 4.0
Toplam		**609**	**586**	

Kitapları bölüm bölüm aldım: tek doküman olsalar split'te bütünüyle tek kümeye düşerlerdi. Kod dosyalarını seed'li 100 dosyayla sınırladım. Gerekçeler: config/sources.csv

Pipeline

13 script, tek komutla baştan sona: run_all.py

Domain Corpus

01	02	03	04	05	06	07	08
İndirme	**Extraction**	**Temizleme**	**Filtre**	**Dedup**	**Split**	**Token**	**İstatistik**
609	608	608	586	586	470/58/58	1,51 M	rapor

Final dokümanlar 250–700 token'lık passage'lara bölünür (2.885 passage), öğretmen model bunlardan örnek üretir:

Instruction Dataset

09	10	11	12	13
Üretim	**Doğrulama**	**Derleme**	**QC örneklemi**	**QC raporu**
3.757	3.263	3.261	200	3.212

Extraction

PDF için PyMuPDF: aynı 24 PDF'te 7,6 kat hızlı, 49 kat az bozuk karakter

PyMuPDF (seçilen)

7,7 sn toplam süre

12 çevrilemeyen karakter

24/24 doküman başarılı

pdfplumber

58,4 sn toplam süre

590 çevrilemeyen karakter

24/24 başarılı, ama bazı kelimeleri birbirine yapıştırdı

HTML: trafilatura. Vikipedi için eklediğim düzeltmeler: kaynak işaretleri ([1]) siliniyor, bağlantılı listeler ve renkli kod blokları düz metne açılıyor, kök işareti korunuyor (O(√n)).

Kitap fontları: Unicode karşılığı olmayan matematik glifleri ve ligatürler çözüldü. Taranmış PDF yok, OCR gerekmedi.

Temizleme · gerçek bir örnek

Sayfa kırılımı ve satır sonu tiresi metinden çıkıyor, bilgi kalıyor

Önce (extraction çıktısı)

```
… of the List and Queue in-
terfaces where the underlying …
… the backing array, a new array
31
§2.1
Array-Based Lists
needs to be allocated and the …
```

Sonra (03_clean)

```
… of the List and Queue interfaces where the …
… the backing array, a new array
needs to be allocated and the …
```

Unicode NFC

NFKC değil: O(n^2) → O(n2) olurdu

Kısa satırlar korunur

BFS, O(n^2), sözde kod satırı bilginin kendisi

Silinenler

sayfa no., başlık/altbilgi, menü, Vikipedi kaynakçası

Sonuç

7.428.646 → 6.257.256 karakter (608 doküman)

Tekrar ayıklama

SHA-256 ve MinHash: 586 dokümanda hiç tekrar yok

Exact duplicate

Normalize metnin SHA-256 özeti

Near duplicate

MinHash (128 permütasyon, 5 kelimelik shingle) ile aday, gerçek Jaccard ≥ 0,85 ise kopya

0,26 Bütün doküman çiftlerinde en yüksek Jaccard. Kaynaklar farklı, kitaplar bölüm bölüm, maddeler elle seçildi.

Eşiği nasıl seçtim: kontrollü değişiklik deneyi

Düzyazı kopyasına yapılan değişiklik	Medyan Jaccard	≥ 0,85
Sona tek satır kaynak bilgisi	0,993	20/20
Satırların %5'i silindi	0,937	18/20
Satırların %20'si silindi	0,737	1/20
Kelimelerin %3'ü değişti	0,758	0/20

Ayrıca en benzer 50 çifti elle etiketledim: hepsi farklı içerik. 0,85 küçük farkları kopya sayıyor, gerçekten farklı metni ayırıyor.

Verinin aşamalar boyunca erimesi · Domain Corpus

609 ham dokümandan 586 final doküman

Ham	Extraction	Temizleme + filtre	Exact dup	Near dup	Final
609	608	586	586	586	586
6 kaynak	−1 çok kısa	−17 kısa, −5 alan dışı	−0	−0	1.512.566 token

Alan dışı elenen 5 doküman: Gauss eliminasyonu, veritabanı ve dosya sistemi indeksleme, işletim sistemi bellek yönetimi, veritabanı depolama motoru, ana bellek veritabanı indeksleri.

Eşikler: 500 karakter (kodda 150), bozuk karakter %15. Alan filtresini 50 dokümanı elle etiketleyerek kalibre ettim. Elenen 23 dokümanın her biri sebebiyle exclusions.csv'de.

Domain Corpus v1.0

1,5 milyon token, doküman düzeyinde 80/10/10

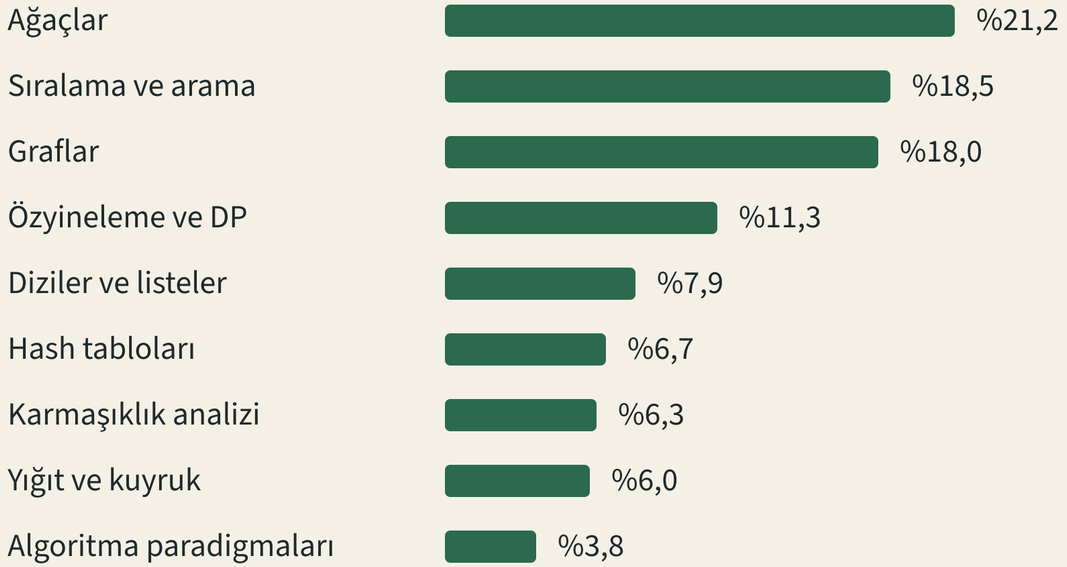
586 doküman

1.512.566 token (Qwen3 tokenizer)

Split	Doküman	Token payı
train	470	%79,3
validation	58	%11,7
test	58	%9,0

Dil (token): İngilizce %89,3 · kod %7,0 · Türkçe %3,8. Kaynağa göre tabakalı; her kitap validation ve testte en az bir bölümle var.

Alt konu dağılımı (token payı)



Instruction Dataset v1.0

3.212 Türkçe örnek, öğrencinin soracağı 10 görev türü

Görev türü	Ne öğretir	Örnek	Pay
Kavram açıklama	Bir yapıyı, algoritmayı ya da kavramı açıklama	596	%18,6
Çoktan seçmeli soru	Dört şıklı soru, doğru şık ve açıklama	397	%12,4
Algoritma izleme	Somut bir girdide adım adım çalıştırma	378	%11,8
Karşılaştırma	İki yapıyı belirli eksenlerde karşılaştırma	378	%11,8
Kod okuma	Kodun ne yaptığını ya da çıktısını açıklama	332	%10,3
Karmaşıklık analizi	Zaman/bellek karmaşıklığı ve gerekçesi	295	%9,2
Hata bulma	Hata konmuş kodda hatalı satırı bulup düzeltme	234	%7,3
Yanlış cevap açıklama	Öğrencinin cevabının neden yanlış olduğu	201	%6,3
Bilgi yetersizliği	Uydurmak yerine sınırını söyleme	201	%6,3
Konu özeti	Bir konunun sade özeti	200	%6,2

%40,7 bağlamlı (ders metni + talimat) · ayrım 2.579 / 324 / 309, kaynak dokümanının kümesinde

3.757 üretilen örneğin 545'i (%14,5) elendi

Öğretmen model

gemini-3.5-flash-lite, temperature 0,7; aynı passage'tan en çok 3 görev

Yargıç model

gemini-3.1-flash-lite, temperature 0; kendi ürettiğini yargılamasın diye farklı model

Koşullar

Ücretsiz katman, günde en çok 500 istek, 19–22 Ekim. Prompt'ları 20 örneklik pilottan sonra düzelttim.

Aşama	Kalan	Elenen	Başlıca sebep
Planlanan görev	3.760	—	3.000 hedef × 1,15 + ek izleme
Üretilen	3.757	3	geçersiz çıktı
Otomatik kontrol	3.629	128	görünmeyen metne atıf, hata konmamış kod
Yargıç model	3.263	366	türe uymuyor 147, yanlış 140, metne dayanmıyor 79
Derleme	3.261	2	passage v1.0'da silinmiş
Manuel kontrol	**3.212**	**49**	200 örnekte başarısız olanlar

En çok elenen tür algoritma izleme (694 görevin 316'sı): talimat somut girdi vermiyor ya da cevap adım adım izlemiyor.

Setten üç örnek

Elle kontrol edip onayladığım örneklerden

Algoritma izleme

“Cyclic Sort algoritmasını [3, 1, 2] dizisi üzerinde adım adım çalıştırabilir misin?”

1. index = 0, nums[0] = 3 ⟶ correct_index = 2, yer değiştirir: [2, 1, 3]
2. nums[0] = 2 ⟶ correct_index = 1: [1, 2, 3]
3–5. 1, 2, 3 yerinde, index ilerler
Sonuç: [1, 2, 3]

Hata bulma

“find_pred_node(x) sözde kodunda arama döngüsü sonsuz döngüye girebiliyor, hata nerede?”

Hatalı satır `r <- r + 1`: üst listelerden alt listelere inilmesi gerekirken r artırılıyor. Düzeltilmiş satır: `r <- r - 1`

Bilgi yetersizliği

“Yukarıdaki metne göre queap veri yapısını Iacono ve Langerman hangi yıl geliştirmiştir?”

“Bu metin veri yapısının geliştirildiği yılı belirtmiyor. … Tam yayın yılını söylemek metne dayanarak mümkün değildir.”

Cevaplar kısaltıldı (…). Format: SFT için `{"messages": [user, assistant]}`; metadata (kaynak doküman, model, prompt özeti, doğrulayan) ayrı dosyada.

Kalite kontrolü

350 öğeyi elle okudum, bulduğum hatalara göre pipeline'ı düzelttim

Domain Corpus · 150 doküman, 6 kontrol

98 → 135

Hepsi başarılı: v0.9'da %65,3, düzeltmelerden sonra aynı 150 doküman v1.0'da %90,0 (%95 GA %84,2–%93,8).

En zayıf: PDF kitaplar (Erickson 2/6, Open Data Structures 5/7): şekil etiketleri, glif kalıntıları.

Instruction Dataset · 200 örnek, 5 kontrol, iki okuma

151 hepsi başarılı (%75,5)

183 cevap doğru (%91,5)

Başarısız 49 örnek setten çıkarıldı. İzleme ve hesapları elle yeniden hesapladım.

En zayıf hata bulma (2/16), en güçlü bilgi yetersizliği (14/14).

Her problemi önce ölçtüm, sonra düzelttim

Problem	Çözüm
Kitap fontlarında Unicode karşılığı olmayan matematik glifleri	Glifleri tek tek eşledim; üs ve indisleri 2^n, log_2 biçiminde yazdım
trafilatura bağlantılı listeleri ve renkli kod bloklarını atıyordu	Bunları düz metne açan kurallar; kayıp kod geri geldi
Corpus 1. tur: 150 dokümanın yalnızca 98'i temiz	Hata türlerini corpus genelinde ölçüp düzelttim: 135/150
Ücretsiz API: günde en çok 500 istek	Kaldığı yerden devam eden üretim; 4 günde 3.757 örnek
İzleme örneklerinin yarısı doğrulamada eleniyordu	Plana 280 izleme ve 30 hata bulma görevi ekledim
Doğru şık soruların %61'inde B	Seed'li şık dengeleme: A 88 · B 121 · C 102 · D 86

Final dönemi planı

Alan uyarlaması modeli ne kadar değiştiriyor?

1 · CPT

Base model + Domain Corpus (train 470 doküman), LoRA/QLoRA

2 · SFT

Alana uyarlanmış model + Instruction Dataset (train 2.579 örnek)

3 · Karşılaştırma

Hazır model · alana uyarlanmış · uyarlanmış + SFT

Ölçüm

Bu vizede ayrılan test kümeleri (58 doküman, 309 örnek). Tasarım raporundaki metrikler: geçerli JSON oranı, şema uyumu, kaynağa sadakat, kör insan değerlendirmesi.

Açık konu

Model: raporda aday Qwen2.5-3B. İki tokenizer aynı, token sayıları ikisi için de geçerli. Seçimi danışmanımla netleştireceğim. Sonra RAG, REST API, Docker, web ve mobil.

Teşekkürler

Sorular

Kod ve belgeler

github.com/SGizem/DSA-DataSet

README · DATASET_CARD · INSTRUCTION_CARD · experiments.md

Veri

Releases › v1.0

DSA-DataSet-v1.0-data.zip, SHA256SUMS ile

Ek · sık sorulacak “neden?” soruları

Her kararın gerekçesi ve kanıtı depoda

Soru	Cevap
Neden PyMuPDF?	Aynı 24 PDF: 7,7 sn ve 12 bozuk karakter; pdfplumber 58,4 sn ve 590
Neden NFC, NFKC değil?	NFKC $O(n^2)$’yi O(n2)’ye çevirir, bilgi kaybolur
Neden kısa satırlar silinmedi?	BFS, $O(n^2)$, sözde kod satırları bu alanda bilginin kendisi
Neden MinHash ve 0,85?	Tek satır ekleme ve %5 satır silme kopya sayılıyor, %20 farklı metin sayılmıyor; 50 çift elle etiketlendi
Neden 80/10/10?	Türkçe doküman az: %5’lik testte 3, %10’lukta 5 Türkçe madde kalıyor
Neden çoğu İngilizce?	Açık lisanslı Türkçe DSA kaynağı yok; Türkçe davranışı instruction seti öğretiyor
Neden 500 karakter?	Rehber’in örnek değeri; elenen 17’si taslak madde, 16’sının konusu corpus’ta uzun hâliyle var
Neden bu metadata?	Rehber §9 alanları + lisans, split, kelime; id/source/url her metni kaynağına bağlıyor
Neden bu görev türleri?	Raporun sistemi: konu anlatımı, sınav sorusu, yanlış cevap açıklaması, kod; %40 bağlamlı (RAG)
Neden iki farklı model?	Yargıç, öğretmenin kendi ürettiğini onaylamasın diye